

LLM 한국어-영어 통합 방법 실험

vocab expansion 기반 한/영 통합(semantic space alignment) 요약

1) 목표 · 설정

- 한/영 동일 의미 입력에 대해 **동일(동등) 응답** 비율 향상
- 영어 벤치마크 성능 유지 + 한국어 성능 향상
- 평가: arc_challenge ↔ ko_arc_challenge (1:1 번역쌍)

Stage 1

Contrastive

Stage 2

LM Head

Stage 3

Full FT

데이터 (Stage 1 병렬)

Dataset	Train	Val
Alhub K2E (5종)	5,729,826	516,150
Total	5.73M	0.52M


Baselines

- Sheared-LLaMA-1.3B-ShareGPT (base)
- polyglot-ko-1.3b (ko strong)


2) 결과 요약

Model	L1 일치	L1 cs	L17 일치	L17 cs
Base	40.02	0.99	40.02	0.93
ckpt-200	34.47	0.98	35.40	0.93
ckpt-400	36.09	0.98	34.90	0.81
ckpt-600	36.26	0.96	35.49	0.77
ckpt-800	35.24	0.93	33.70	0.74

대표 플롯



한/영 representation
cosine similarity
(validation)



학습 곡선(대표 loss) – 장기
학습 시 추세 확인

결론 · 다음 액션

- CL 단독은 일치도 개선에 유리, generation 결합 시 효과가 상쇄될 수 있음
- 중간 layer(15~17)에서 의미 표현이 강해지는 패턴이 관찰됨
- 다음: **CL-only vs Gen-only vs CL+Gen** 대조 실험 + 스케줄/가중치 탐색

LLM 한/영 통합 실험 – 1-page summary

A4 hard-fit layout (overflow hidden)